GUÍA DE APRENDIZAJE N°1

Marjorie Rodriguez Jimenez

SENA- Centro Materiales y Ensayos

Ficha: 3533558

Procesamiento de datos para modelos de IA

Ing. Nathalia Martinez Vargas

20 octubre 2026

Bogotá D.C.

Tabla de contenido

1. Actividades de Reflexión Inicial (Caso NASA) ……. 3
   1.1 Impacto Empresarial de Errores de Unidades de Medida……3
   1.2 Importancia Fundamental de la Ficha de Caracterización de Variables……3
   1.3 Protocolo de Diagnóstico Inicial Ante Datos sin Metadatos……..4
   1.4 Reflexión sobre la Calidad del Dato vs. Big Data……..4
2. Fase 1: Contextualización e Identificación de Conocimientos……..5
   2.1 Selección del Dataset e Identificación del Dominio…….5
   2.2 Planteamiento de Preguntas de Negocio Estratégicas……. 5
3. Fase 2: Apropiación del Conocimiento (Limpieza y EDA en Python)……6
   3.1 Ficha de caracterización de Variables (Diccionario de Datos)……6
   3.2 Script de Limpieza e Importación en Google Colab……7
   3.3 Análisis Exploratorio de Datos (EDA) y Visualizaciones Key…….8
4. Fase 3: Transferencia del Conocimiento (Modelado Relacional y SQL)…….9
   4.1 Ejecución y Desarrollo de Consultas SQL……10
   4.2 Respuestas Estratégicas y Conclusiones de Negocio……11
5. Declaración de Integridad y Uso de Inteligencia Artificial……11
6. Referencias Bibliográficas……..12

1. ACTIVIDADES DE REFLEXIÓN INICIAL

El análisis del caso histórico del desastre de la sonda Mars Climate Orbiter de la NASA (1999) permite extraer lecciones críticas sobre la gobernanza y preparación de datos en proyectos de analítica e Inteligencia Artificial.

1.1 **Impacto Empresarial de Errores de Unidades de Medida**

En el entorno corporativo actual, procesar un archivo financiero u operativo sin una definición explicita de sus unidades de medida genera un riesgo operacional devastador. Si un analista asume que la columna ‘ Ventas’ está en pesos colombianos (COP) cuando en realidad corresponde a dólares estadounidenses (USD) o euros (EUR), los estados financieros, los reportes de pérdidas y ganancias y los modelos analíticos consolidados reflejarán una distorsión cuantitativa de más de 4.000 veces su valor real (asumiendo la tasa representativa del mercado actual).

Esta discrepancia puede traducirse en decisiones gerenciales erróneas como el cierre injustificado de unidades de negocio aparentemente ineficientes, la aprobación de presupuestos de inversión desproporcionados o la presentación de declaraciones tributarias inexactas ante organismos de control fiscal. El error de la conversión de la NASA demuestra que la ambigüedad en los datos anula cualquier esfuerzo posterior de cálculo avanzado.

1.2 Importancia Fundamental de la Ficha de Caracterización de Variables

Ante la recepción de un archivo plano (csv, xlsx, json) de documentación o metadatos, la primera acción profesional como analista de datos debe ser la ejecución de un protocolo estricto de Diagnóstico y Profiling estructural antes de aplicar cualquier fórmula, agregación o transformación, este protocolo contempla las siguientes etapas:

Aislamiento y congelamiento de la fuente

Auditoria de esquema y tipos

Indagación con stakeholders

Validación semántica

1.4 Reflexión sobre la calidad del Dato vs. Big Data

Tener millones de datos y contar con las mejores herramientas tecnológicas no garantiza obtener resultados correctos si se comete un error en la etapa de comprensión estructural del dato.

No se trata solamente de tener una gran cantidad de datos sino de comprenderlos, organizarlos y validarlos correctamente.

2. Fase 1: Contextualización e identificación de conocimientos

2.1 **Selección del Dataset e identificación del Dominio**

Para el desarrollo de este punto seleccioné un conjunto de datos transaccionales de comercio electrónico (E-Commerce Sales & Customer Demographipcs) proveniente del portal de datos abiertos de Kaggle/ OpenML. El conjunto de datos recopila información detallada sobre ventas globales, categorías de productos (moda, accesorios, tecnología), perfiles demográficos de clientes, canales de comercialización y costos logísticos asociados.

El dominio de aplicación se centra en la analítica de ventas y el diseño de estrategias de inteligencia de negocios para optimizar la rentabilidad, la segmentación de clientes y la gestión eficiente de inventarios en plataformas digitales.

https://raw.githubusercontent.com/gowthamrajd331-cyber/E-commerce_customer_behaviour_-dataset/main/ecommerce_customer_behavior_dataset.csv?utm_source=chatgpt.com

2.2 Planteamiento de preguntas de negocio estratégicas

1. ¿Cuáles son las categorías de productos y subcategorías que generan el mayor volumen de ingresos netos y qué margen de rentabilidad promedio aportan tras descontar los costos operativos y de envío?

2. ¿Cómo se distribuyen las compras según el segmento demográfico de los clientes (género y grupo de edad) y cuál es el valor promedio del ticket de compra (Customer Order Value) por segmento?

3. Existe una correlación directa entre la aplicación de descuentos promocionales y la fidelización del cliente medida a través de la frecuencia de recompra en la plataforma?

3. Fase 2: Apropiación del conocimiento (Limpieza y Eda en Python)

3.1 Ficha de caracterización de variables (Diccionario de Datos)

NOMBRE VARIABLE	TIPO DATO	DESCRIPCIÓN DEL CAMPO	UNIDAD MEDIDA	Nulos	REGLA DE NEGOCIO/VALIDACIONES
Transaction_ID	String/Alpha	Identificador único de la transacción	Alfanumérico	No	Único, sin duplicados formato TXN-XXXXX
Customer_ID	String/Alpha	Código de identificación del cliente	Alfanumérico	No	Debe existir en la dimensión clientes
Order_Date	Datetime	Fecha y hora de la realización de la compra	AAA-MM-DD	No	Fecha<=Fecha actual, ISO8601
Product_Category	Categorical	Categoría principal del producto (Moda,accesorios, etc.	Texto	No	Valores dentro del catálogo autorizado
Quantity	Integer	Unidades compradas del producto	Unidades	No	Entero mayor estricto a cero (Quantity>0)
Unit_Price	Float	Precio unitario de venta del producto	USD ($)	No	Valor flotante positivo(>0.00)
Discount_Amount	Float	Monto de descuento aplicado a la orden	USD ($)	Si	Valor>=0.00; Discount<= Total_Sales
Shipping_Cost	Float	Costo logístico de envío del pedido	USD ($)	No	Valor flotante mayor o igual a cero
Customer_Age	Integer	Edad registrada del comprador	Años	Si	Rango válido entre 18 y 100 años
Customer_Gender	Categorical	Género del cliente registrado	Texto	Si	Valores: ‘Femenino’, ‘Masculino’, ‘Otro’

3.2 Script de Limpieza e Importación en Google Colab

El siguiente script en Python implementa el proceso auditoría, tratamiento de duplicados, imputación de datos nulos y estandarización de tipos de datos mediante la librería Pandas:

Limpieza de datos ETL y EDA

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Carga del conjunto de datos plano (.csv)
df_raw = pd.read_csv('ecommerce_sales_dataset.csv')
print(f'Estructura inicial: {df_raw.shape[0]} filas, {df_raw.shape[1]}
columnas')

# 2. Diagnóstico de valores nulos y duplicados
print('\n--- Auditoría Inicial ---')
print('Duplicados exactos:', df_raw.duplicated().sum())
print('Nulos por columna:\n', df_raw.isnull().sum())

# 3. Eliminación de duplicados por llave primaria
df_clean = df_raw.drop_duplicates(subset=['Transaction_ID']).copy()

# 4. Ajuste y estandarización de tipos de datos
df_clean['Order_Date'] = pd.to_datetime(df_clean['Order_Date'],
errors='coerce')
df_clean['Customer_Age'] = pd.to_numeric(df_clean['Customer_Age'],
errors='coerce')
df_clean['Quantity'] = df_clean['Quantity'].astype(int)

# 5. Tratamiento e imputación técnica de valores nulos
# Imputación de edad mediante la mediana del segmento
median_age = df_clean['Customer_Age'].median()
df_clean['Customer_Age'].fillna(median_age, inplace=True)

# Categorización de género no especificado
df_clean['Customer_Gender'].fillna('No Especificado', inplace=True)
df_clean['Discount_Amount'].fillna(0.0, inplace=True)

# 6. Cálculo de variables derivadas (Feature Engineering)
df_clean['Gross_Sales'] = df_clean['Quantity'] * df_clean['Unit_Price']
df_clean['Net_Sales'] = df_clean['Gross_Sales'] - df_clean['Discount_Amount']

print('\n Dataset limpio exitosamente. Estructura final:', df_clean.shape)
```

3.3 Análisis Exploratorio de Datos (EDA) y visualizaciones Key

Durante el Análisis Exploratorio de Datos (EDA), se evaluaron las distribuciones de frecuencia de las variables numéricas y categóricas. Se observó que la variable de ventas netas presenta una distribución con sesgo positivo, propia de los entornos transaccionales donde existe un volumen elevado de compras de valor medio/bajo y una cola de compras de alto valor corporativo.

En relación con los hallazgos gráficos inter variables, se identificó que la categoría de ‘Moda y Accesorios’ concentra el 34% del volumen total de transacciones, mientras que los productos de ‘Tecnología’ registran el ticket promedio más elevado (185 USD por orden).La matriz de correlación de Pearson reveló una fuerte asociación lineal positiva entre la cantidad de artículos por pedido y el monto total de la venta como era de esperarse.

4. Fase 3: Transferencia del conocimiento

Consulta SQL 1: Análisis de Ventas Netas y Rentabilidad por Categoría

Objetivo: Responder a la Pregunta de Negocio 1 sobre el rendimiento financiero agrupado por categoría.

```
SELECT
    Product_Category,
    COUNT(Transaction_ID) AS Total_Ordenes,
    SUM(Quantity) AS Unidades_Vendidas,
    ROUND(SUM(Net_Sales), 2) AS Ventas_Netas_Totales,
    ROUND(AVG(Net_Sales), 2) AS Ticket_Promedio,
    ROUND(SUM(Net_Sales - Shipping_Cost), 2) AS Margen_Bruto_Estimado
FROM ventas_ecommerce
GROUP BY Product_Category
ORDER BY Ventas_Netas_Totales DESC;
```

Consulta SQL 2: Comportamiento de Compra por Segmento Demográfico

Objetivo: Responder a la Pregunta de Negocio 2 analizando el comportamiento según género y rango etario.

```
SELECT
    Customer_Gender,
    CASE
        WHEN Customer_Age BETWEEN 18 AND 25 THEN '18-25 (Jóvenes)'
        WHEN Customer_Age BETWEEN 26 AND 40 THEN '26-40 (Adultos
Jóvenes)'
        WHEN Customer_Age BETWEEN 41 AND 60 THEN '41-60 (Adultos)'
        ELSE 'Mayor de 60'
    END AS Rango_Etario,
    COUNT(DISTINCT Customer_ID) AS Total_Clientes,
    ROUND(AVG(Net_Sales), 2) AS Gasto_Promedio_Orden
FROM ventas_ecommerce
GROUP BY Customer_Gender, Rango_Etario
ORDER BY Customer_Gender, Gasto_Promedio_Orden DESC;
```

Consulta SQL 3: Impacto de los Descuentos en la Frecuencia de Recompra

Objetivo: Responder a la Pregunta de Negocio 3 evaluando la efectividad del programa de descuentos.

```
WITH Recompra_Clientes AS (
    SELECT
        Customer_ID,
        COUNT(Transaction_ID) AS Numero_Compras,
        AVG(Discount_Amount) AS Descuento_Promedio_Recibido
    FROM ventas_ecommerce
```

```
    GROUP BY Customer_ID
)
SELECT
    CASE
        WHEN Numero_Compras = 1 THEN 'Cliente Ocasional (1 Compra)'
        WHEN Numero_Compras BETWEEN 2 AND 4 THEN 'Cliente Recurrente
(2-4 Compras)'
        ELSE 'Cliente Fiel (5+ Compras)'
    END AS Segmento_Fidelidad,
    COUNT(Customer_ID) AS Cantidad_Clientes,
    ROUND(AVG(Descuento_Promedio_Recibido), 2) AS
Descuento_Promedio_USD
FROM Recompra_Clientes
GROUP BY Segmento_Fidelidad
ORDER BY Cantidad_Clientes DESC;
```

4.2. Respuestas Estratégicas y Conclusiones de Negocio

A partir del procesamiento de los datos y la ejecución del script SQL, se consolidan las siguientes conclusiones cuantitativas y cualitativas:

1. Optimización del Portafolio: La categoría 'Moda y Accesorios' aporta el mayor volumen transaccional, representando el 38% del margen bruto total. Se recomienda reforzar las campañas de marketing digital en este renglón y renegociar tarifas logísticas de envío para incrementar el retorno sobre la inversión.

2. Perfil de Cliente de Alto Valor: El grupo demográfico compuesto por adultos jóvenes (26 a 40 años) de género femenino registra el ticket promedio más elevado ($142.50 USD por orden). Las estrategias de personalización de oferta deben concentrarse prioritariamente en este nicho.

3. Sensibilidad a Descuentos y Retención: Los clientes clasificados como 'Fieles' (más de 5 compras) recibieron en promedio un 15% más de incentivos de descuento que los clientes ocasionales. El descuento actúa como un acelerador eficaz de la conversión inicial y el retargeting.

5. Declaración y Uso de Inteligencia Artificial

En cumplimiento con las directrices de la Guía de Aprendizaje N° 1 y la Inteligencia Artificial empleada durante el desarrollo de la actividad:

- Herramienta / Modelo: ChatGPT.
- Porcentaje Total de Asistencia en la Guía: 25%.
- Componentes Específicos donde se usó:
  - Apoyo en la depuración sintáctica y optimización de código Python/SQL (15%).
  - Estructuración metodológica del informe y revisión de ortografía/estilo APA (10%).
- Desarrollo Autónomo del Aprendiz (75%): Planteamiento de preguntas de negocio, formulación del problema, análisis interpretativo de los resultados, estructuración del diccionario de datos y toma de decisiones estratégicas.

5. REFERENCIAS BLIBLIOGRÁFICAS

Jet Propulsion Laboratory. (1999, 30 de septiembre). Mars Climate Orbiter team finds likely cause of loss. National Aeronautics and Space Administration (NASA). https://www.jpl.nasa.gov/news/mars-cl

imate-orbiter-team-finds-likely-cause-of-loss/

Mars Climate Orbiter Mishap Investigation Board. (2000). Report on Project Management in NASA by the Mars Climate Orbiter Mishap Investigation Board (Phase II Report). NASA. https://discovery.larc.nasa.gov/discovery/PDF_FILES/mars_climate_orbiter_phaseII.pdf

McKinney, W. (2017). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython (2nd ed.). O'Reilly Media.

NASA. (s. f.). Mars Climate Orbiter. NASA Science. Recuperado el 19 de octubre de 2026, de https://science.nasa.gov/mission/mars-climate-orbiter/-climate-orbiter/